

## 4 i 5. TESTY STATYSTYCZNE

**Definicja.** Hipotezą statystyczną nazywamy przypuszczenie dotyczące nieznanego rozkładu badanej cechy populacji, o prawdziwości lub fałszywości którego wnioskujemy się na podstawie pobranej próbki.

**PRZYKŁADY:**

1. Wysuwamy hipotezę, że badana cecha ma rozkład normalny.
2. Wiemy, że badana cecha ma rozkład normalny o nieznannej wartości średniej  $\mu$  i znanym odchyleniu standardowym  $\sigma = 1$ . Wysuwamy hipotezę, że  $\mu = 5$ .
3. Dane są dwa zbiory obserwacji, np. wysokości plonów uzyskane podczas nawożenia nawozem A i nawozem B.
  - (a) Wysuwamy hipotezę, że oba zbiory można traktować jako pochodzące z populacji o tym samym rozkładzie.
  - (b) Z wcześniejszych badań wiemy, że zbiory te można traktować jako pochodzące z populacji o rozkładach normalnych odpowiednio  $N(\mu_1, \sigma_1)$  i  $N(\mu_2, \sigma_2)$ , gdzie parametry  $\mu_1, \mu_2, \sigma_1$  i  $\sigma_2$  są nieznanymi, ale takimi, że  $\sigma_1 = \sigma_2$ . Wysuwamy przypuszczenie, że średnia wartość plonów przy nawożeniu nawozem A jest większa niż średnia wartość plonów przy nawożeniu nawozem B (tzn. że  $\mu_1 > \mu_2$ ).

**Definicja.** Hipotezy, które dotyczą wyłącznie wartości parametru lub parametrów rozkładu badanej cechy nazywamy hipotezami parametrycznymi. Hipotezy, które nie są hipotezami parametrycznymi nazywamy hipotezami nieparametrycznymi.

W powyższym przykładzie hipotezy 2 i 3(b) są parametryczne, natomiast hipotezy 1 i 3(a) są nieparametryczne.

**Definicja.** Hipotezą prostą nazywamy hipotezę, która jednoznacznie określa rozkład badanej cechy. Hipotezą złożoną nazywamy hipotezę, która określa całą grupę rozkładów.

Hipoteza z przykładu 2 jest hipotezą prostą. Pozostałe hipotezy są złożone.

W praktyce rozważamy dwie hipotezy: hipotezę zerową (będziemy ją oznaczać  $H_0$ ) i hipotezę alternatywną (tą będziemy oznaczać  $H_1$ ). Jeśli odrzucamy hipotezę zerową, to przyjmujemy hipotezę alternatywną i na odwrót.

**PRZYKŁAD:**

Wiemy, że wysokość plonów przy nawożeniu starą metodą ma rozkład normalny o średniej 5 i odchyleniu standardowym 1:  $N(5, 1)$  i że wysokość plonów przy nawożeniu nową metodą ma rozkład normalny o tym samym odchyleniu standardowym  $\sigma = 1$  ale o nieznannej średniej  $\mu$ :  $N(\mu, 1)$ . Chcemy sprawdzić czy nowa metoda zwiększyła średnią wysokość plonów.

W tym celu będziemy testować  $H_0 : \mu = 5$  przeciwko  $H_1 : \mu > 5$ .

Przeprowadzamy eksperyment losowy. Wynik takiego eksperymentu to wektor losowy  $\mathbb{X} = (X_1, X_2, \dots, X_n)$  o wartościach w  $\mathbb{R}^n$ .

**Definicja.** Statystyką testową nazywamy funkcję  $\delta(X_1, X_2, \dots, X_n)$ , która służy do weryfikacji  $H_0$  przeciwko  $H_1$ . Zbiór wszystkich możliwych wartości funkcji  $\delta$  dzielimy na dwa rozłączne zbiory  $W$  i  $W'$  takie, że:

- jeśli  $\delta(x_1, x_2, \dots, x_n) \in W$ , to  $H_0$  odrzucamy,
- jeśli  $\delta(x_1, x_2, \dots, x_n) \in W'$ , to  $H_0$  przyjmujemy.

W nazywamy zbiorem krytycznym testu (zbiorem odrzuceń  $H_0$ ).

Musimy dobrze skonstruować statystykę testową i rozsądnie dobrać zbiór krytyczny, tak by podejmować decyzje zgodne z rzeczywistością. Jednak, ponieważ decyzje podejmujemy jedynie na podstawie próbki, nie mamy całkowitej informacji o badanej populacji i w związku z tym zawsze jesteśmy narażeni na popełnienie błędu - podjęcie decyzji niezgodnej z rzeczywistością. Dokładniej, możemy popełnić jeden z dwóch błędów:

1. odrzucić  $H_0$  w sytuacji, gdy jest ona prawdziwa (tzw. błąd pierwszego rodzaju);
2. przyjąć  $H_0$  w sytuacji, gdy jest ona fałszywa (tzw. błąd drugiego rodzaju).

Chcielibyśmy by prawdopodobieństwa obu tych błędów były jak najmniejsze. Niestety, gdy przy ustalonej statystyce testowej, zmieniamy  $W$  tak by malał błąd pierwszego rodzaju, to błąd drugiego rodzaju rośnie i na odwrót. Postępujemy zatem tak:

- ustalamy z góry maksymalną wartość prawdopodobieństwa błędu pierwszego rodzaju, oznaczamy tą wartość  $\alpha$  i nazywamy ją poziomem istotności testu (zwyczajowo przyjmuje się  $\alpha = 0,01$  lub  $\alpha = 0,05$ , czasami  $\alpha = 0,1$ );

- zbiór krytyczny  $W$  wyznaczamy tak by prawdopodobieństwo błędu pierwszego rodzaju nie przekraczało  $\alpha$  i by prawdopodobieństwo błędu drugiego rodzaju było możliwie najmniejsze.

Zapisujemy to symbolicznie:

$$\underbrace{P(\delta(X_1, X_2, \dots, X_n) \in W | H_0)}_{\text{prawdop. błędu pierwszego rodzaju}} \leq \alpha \quad \text{i}$$

$$\underbrace{P(\delta(X_1, X_2, \dots, X_n) \notin W | H_1)}_{\text{prawdop. błędu drugiego rodzaju}} - \text{możliwie najmniejsze}$$

**Definicja.** Moc testu parametrycznego (power of the test) to funkcja zmiennej  $\theta$  (gdzie  $\theta$  to badany parametr) dana wzorem

$$\beta(\theta) = P(\underbrace{\delta(X_1, X_2, \dots, X_n)}_{\text{statystyka testowa}} \in W | \theta) = \text{prawdop. odrzucenia } H_0 \text{ w sytuacji, gdy nieznan parametr przyjmuje wartość } \theta.$$

Jeśli  $H_0 : \theta = \theta_0$ , to  $\beta(\theta_0) = P(\delta(X_1, X_2, \dots, X_n) \in W | \theta_0) = P(\delta(X_1, X_2, \dots, X_n) \in W | H_0) = \text{prawdopodobieństwo błędu pierwszego rodzaju}$ .

Natomist jeśli  $H_1 : \theta = \theta_1$ , to wówczas  $\beta(\theta_1) = P(\delta(X_1, X_2, \dots, X_n) \in W | \theta_1) = P(\delta(X_1, X_2, \dots, X_n) \in W | H_1) = 1 - P(\delta(X_1, X_2, \dots, X_n) \notin W | H_1) = 1 - \text{prawdopodobieństwo błędu drugiego rodzaju}$ .

**Definicja.** Najmniejszy poziom istotności, przy którym zaobserwowana wartość statystyki testowej prowadzi do odrzucenia  $H_0$ , nazywamy p-wartością ( $p$ -value) przeprowadzonego testu. Tzn.

$$\begin{aligned} p\text{-value} \leq \alpha &\Rightarrow \text{odrzucaamy } H_0, \\ p\text{-value} > \alpha &\Rightarrow \text{nie ma podstaw do odrzucenia } H_0 \text{ (przyjmujemy } H_0). \end{aligned}$$

# TESTY PARAMETRYCZNE

Podstawowe statystyki próbkowe i funkcje w R wyliczające te statystyki	
średnia z próby: $\bar{x} = \frac{1}{n} \sum_{j=1}^n x_j$ $> \text{mean}(\text{dane})$	wariancja z próby: $s^2 = \frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})^2$ $> \text{var}(\text{dane})$

Oznaczenia podstawowych kwantyli i funkcje w R wyliczające te kwantyle			
dla rozkładu normalnego	dla rozkładu t-Studenta	dla rozkładu chi-kwadrat	dla rozkładu F-Snedecora
$z_\alpha$	$t_{\alpha,n}$	$\chi_{\alpha,n}^2$	$F(\alpha, n, m)$
$> \text{qnorm}(\alpha)$	$> \text{qt}(\alpha, n)$	$> \text{qchisq}(\alpha, n)$	$\text{qf}(\alpha, n, m)$

Weryfikacje hipotez dotyczących wartości średniej na poziomie istotności $\alpha$		
<b>UWAGA:</b> jeżeli wyznaczone wartości statystyk ( $Z$ lub $T$ ) należą do odpowiednich zbiorów krytycznych, to $H_0$ odrzucamy.		
<b>Model I.</b> $X \sim N(\mu, \sigma)$ , $\mu$ - nieznane, $\sigma$ - znane. Hipoteza zerowa $H_0 : \mu = \mu_0$ . Statystyka testowa $Z = \frac{\bar{x} - \mu_0}{\sigma} \sqrt{n}$ .		
Hipoteza alternatywna $H_1 : \mu \neq \mu_0$ Zbiór krytyczny $W = (-\infty; -z_{1-\alpha/2}) \cup (z_{1-\alpha/2}; +\infty)$	Hipoteza alternatywna $H_1 : \mu > \mu_0$ Zbiór krytyczny $W = (z_{1-\alpha}; +\infty)$	Hipoteza alternatywna $H_1 : \mu < \mu_0$ Zbiór krytyczny $W = (-\infty; -z_{1-\alpha})$
<b>Model II (t.test).</b> $X \sim N(\mu, \sigma)$ , $\mu$ - nieznane, $\sigma$ - nieznane. Hipoteza zerowa $H_0 : \mu = \mu_0$ . Statystyka testowa $T = \frac{\bar{x} - \mu_0}{s} \sqrt{n}$ .		
Hipoteza alternatywna $H_1 : \mu \neq \mu_0$ Zbiór krytyczny $W = (-\infty; -t_{1-\alpha/2, n-1}) \cup (t_{1-\alpha/2, n-1}; +\infty)$	Hipoteza alternatywna $H_1 : \mu > \mu_0$ Zbiór krytyczny $W = (t_{1-\alpha, n-1}; +\infty)$	Hipoteza alternatywna $H_1 : \mu < \mu_0$ Zbiór krytyczny $W = (-\infty; -t_{1-\alpha, n-1})$
<b>Model III.</b> $X$ ma rozkład dowolny (próba duża $n \geq 100$ ). Hipoteza zerowa $H_0 : \mu = \mu_0$ . Statystyka testowa $Z = \frac{\bar{x} - \mu_0}{s} \sqrt{n}$ .		
Hipoteza alternatywna $H_1 : \mu \neq \mu_0$ Zbiór krytyczny $W = (-\infty; -z_{1-\alpha/2}) \cup (z_{1-\alpha/2}; +\infty)$	Hipoteza alternatywna $H_1 : \mu > \mu_0$ Zbiór krytyczny $W = (z_{1-\alpha}; +\infty)$	Hipoteza alternatywna $H_1 : \mu < \mu_0$ Zbiór krytyczny $W = (-\infty; -z_{1-\alpha})$
<b>Model IV (prop.test).</b> $X$ ma rozkład dwupunktowy $P(X = 1) = p$ , $P(X = 0) = q = 1 - p$ , $p$ - nieznane, $n\hat{p} \geq 5$ i $n\hat{q} \geq 5$ , gdzie $\hat{p} = \frac{k}{n} = \frac{\text{ilość sukcesów}}{\text{ilość prób}}$ , $\hat{q} = 1 - \hat{p}$ . Hipoteza zerowa $H_0 : p = p_0$ . Statystyka testowa $Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$ .		
Hipoteza alternatywna $H_1 : p \neq p_0$ Zbiór krytyczny $W = (-\infty; -z_{1-\alpha/2}) \cup (z_{1-\alpha/2}; +\infty)$	Hipoteza alternatywna $H_1 : p > p_0$ Zbiór krytyczny $W = (z_{1-\alpha}; +\infty)$	Hipoteza alternatywna $H_1 : p < p_0$ Zbiór krytyczny $W = (-\infty; -z_{1-\alpha})$
Jeśli w modelu IV nie jest spełnione założenie, że $n\hat{p} \geq 5$ i $n\hat{q} \geq 5$ , to zamiast prop.test używamy testu dokładnego <b>binom.test</b> .		

Weryfikacja hipotezy dotyczącej jednej wariancji na poziomie istotności $\alpha$		
<b>UWAGA:</b> jeżeli wyznaczona wartość statystyki $\chi^2$ należy do odpowiedniego zbioru krytycznego, to $H_0$ odrzucamy.		
<b>Model.</b> $X \sim N(\mu, \sigma)$ , $\mu$ - nieznane, $\sigma$ - nieznane. Hipoteza zerowa $H_0 : \sigma^2 = \sigma_0^2$ . Statystyka testowa $\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$ .		
Hipoteza alternatywna $H_1 : \sigma^2 \neq \sigma_0^2$ Zbiór krytyczny $W = (0; \chi_{\alpha/2, n-1}^2) \cup (\chi_{1-\alpha/2, n-1}^2; +\infty)$	Hipoteza alternatywna $H_1 : \sigma^2 > \sigma_0^2$ Zbiór krytyczny $W = (\chi_{1-\alpha, n-1}^2; +\infty)$	Hipoteza alternatywna $H_1 : \sigma^2 < \sigma_0^2$ Zbiór krytyczny $W = (0; \chi_{\alpha, n-1}^2)$

Weryfikacja hipotezy dotyczącej równości dwóch wariancji na poziomie istotności $\alpha$	
<b>UWAGA:</b> jeżeli wyznaczona wartość statystyki $F$ należy do zbioru krytycznego $W$ , to $H_0$ odrzucamy.	
<b>Model I. (test F: var.test)</b> $X \sim N(\mu_1, \sigma_1)$ , $Y \sim N(\mu_2, \sigma_2)$ , $\mu_1, \mu_2, \sigma_1, \sigma_2$ - nieznane; dysponujemy niezależnymi próbami losowymi z tych populacji. Hipoteza zerowa $H_0 : \sigma_1^2 = \sigma_2^2$ . Statystyka testowa $F = s_1^2/s_2^2$ (w liczniku jest większa z wariancji).	
Hipoteza alternatywna $H_1 : \sigma_1^2 \neq \sigma_2^2$ Zbiór krytyczny $W = (F(1 - \alpha/2, n_1 - 1, n_2 - 2); +\infty)$	Hipoteza alternatywna $H_1 : \sigma_1^2 > \sigma_2^2$ Zbiór krytyczny $W = (F(1 - \alpha, n_1 - 1, n_2 - 2); +\infty)$

Weryfikacje hipotez dotyczących dwóch średnich na poziomie istotności $\alpha$			
<b>UWAGA:</b> jeżeli wyznaczone wartości statystyk ( $Z$ lub $T$ ) należą do odpowiednich zbiorów krytycznych, to $H_0$ odrzucamy.			
<b>Model I.</b> $X \sim N(\mu_1, \sigma_1)$ , $Y \sim N(\mu_2, \sigma_2)$ , $\mu_1, \mu_2$ - nieznane, $\sigma_1, \sigma_2$ - znane; dysponujemy niezależnymi próbkami losowymi z tych populacji. Hipoteza zerowa $H_0 : \mu_1 = \mu_2$ . Statystyka testowa $Z = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$ .			
Hipoteza alternatywna $H_1 : \mu_1 \neq \mu_2$	Hipoteza alternatywna $H_1 : \mu_1 > \mu_2$	Hipoteza alternatywna	$H_1 : \mu_1 < \mu_2$
Zbiór krytyczny $W = (-\infty; -z_{1-\alpha/2}) \cup (z_{1-\alpha/2}; +\infty)$	Zbiór krytyczny $W = \langle z_{1-\alpha}; +\infty \rangle$	Zbiór krytyczny	$W = (-\infty; -z_{1-\alpha})$
<b>Model II. (unpaired <math>t</math>-test: <math>\mathbf{t.test(...,paired=FALSE, var.equal=TRUE)}</math>)</b> $X \sim N(\mu_1, \sigma_1)$ , $Y \sim N(\mu_2, \sigma_2)$ , $\mu_1, \mu_2$ - nieznane, $\sigma_1, \sigma_2$ - nieznane, ale takie, że $\sigma_1 = \sigma_2$ ; dysponujemy niezależnymi próbkami losowymi z tych populacji. Hipoteza zerowa $H_0 : \mu_1 = \mu_2$ . Statystyka testowa $T = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2} \left( \frac{1}{n_1} + \frac{1}{n_2} \right)}}$ .			
Hipoteza alternatywna $H_1 : \mu_1 \neq \mu_2$	Hipoteza alternatywna $H_1 : \mu_1 > \mu_2$	Hipoteza alternatywna	$H_1 : \mu_1 < \mu_2$
Zbiór krytyczny $W = (-\infty, -t_{1-\alpha/2, n_1+n_2-2}) \cup (t_{1-\alpha/2, n_1+n_2-2}; +\infty)$	Zbiór krytyczny $W = \langle t_{1-\alpha, n_1+n_2-2}; +\infty \rangle$	Zbiór krytyczny	$W = (-\infty, -t_{1-\alpha, n_1+n_2-2})$
Jeśli w <b>modelu II</b> nie jest spełnione założenie, że $\sigma_1 = \sigma_2$ , to zamiast $\mathbf{t.test(...,paired=FALSE, var.equal=TRUE)}$ należy użyć $\mathbf{t.test(...,paired=FALSE, var.equal=FALSE)}$			
<b>Model III. (paired <math>t</math>-test: <math>\mathbf{t.test(..., paired=TRUE)}</math>)</b> $X - Y \sim N(\mu, \sigma)$ , $\mu, \sigma$ - nieznane. Dysponujemy parami obserwacji, gdzie pary są wzajemnie niezależne. Hipoteza zerowa $H_0 : \mu_1 = \mu_2$ . Statystyka testowa $T = \frac{\bar{z}}{s_z} \sqrt{n}$ , gdzie $z_i = x_i - y_i, i = 1, 2, \dots, n$ .			
Hipoteza alternatywna $H_1 : \mu_1 \neq \mu_2$	Hipoteza alternatywna $H_1 : \mu_1 > \mu_2$	Hipoteza alternatywna	$H_1 : \mu_1 < \mu_2$
Zbiór krytyczny $W = (-\infty; -t_{1-\alpha/2, n-1}) \cup (t_{1-\alpha/2, n-1}; +\infty)$	Zbiór krytyczny $W = \langle t_{1-\alpha, n-1}; +\infty \rangle$	Zbiór krytyczny	$W = (-\infty; -t_{1-\alpha, n-1})$
<b>Model IV.</b> Cechy $X, Y$ mają rozkłady dowolne ( $n_1 \geq 100, n_2 \geq 100$ ), $\mu_1, \mu_2, \sigma_1, \sigma_2$ - nieznane; dysponujemy niezależnymi próbkami losowymi z tych populacji. Hipoteza zerowa $H_0 : \mu_1 = \mu_2$ . Statystyka testowa $Z = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$ .			
Hipoteza alternatywna $H_1 : \mu_1 \neq \mu_2$	Hipoteza alternatywna $H_1 : \mu_1 > \mu_2$	Hipoteza alternatywna	$H_1 : \mu_1 < \mu_2$
Zbiór krytyczny $W = (-\infty; -z_{1-\alpha/2}) \cup (z_{1-\alpha/2}; +\infty)$	Zbiór krytyczny $W = \langle z_{1-\alpha}; +\infty \rangle$	Zbiór krytyczny	$W = (-\infty; -z_{1-\alpha})$
<b>Model V (prop.test).</b> Cechy $X, Y$ mają rozkłady dwupunktowe, $P(X=1) = p_1 = 1 - P(X=0)$ , $P(Y=1) = p_2 = 1 - P(Y=0)$ , $p_1, p_2$ - nieznane, $n_1 \hat{p}_1 \geq 5$ i $n_1(1 - \hat{p}_1) \geq 5$ i $n_2 \hat{p}_2 \geq 5$ i $n_2(1 - \hat{p}_2) \geq 5$ .			
Hipoteza zerowa $H_0 : p_1 = p_2$ . Statystyka testowa $Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\frac{\hat{p}\hat{q}}{n}}}$ , gdzie $\hat{p}_1 = \frac{k_1}{n_1}$ , $\hat{p}_2 = \frac{k_2}{n_2}$ , $\bar{p} = \frac{k_1+k_2}{n_1+n_2}$ , $\hat{q} = 1 - \bar{p}$ , $n = \frac{n_1 n_2}{n_1 + n_2}$ .			
Hipoteza alternatywna $H_1 : p_1 \neq p_2$	Hipoteza alternatywna $H_1 : p_1 > p_2$	Hipoteza alternatywna	$H_1 : p_1 < p_2$
Zbiór krytyczny $W = (-\infty; -z_{1-\alpha/2}) \cup (z_{1-\alpha/2}; +\infty)$	Zbiór krytyczny $W = \langle z_{1-\alpha}; +\infty \rangle$	Zbiór krytyczny	$W = (-\infty; -z_{1-\alpha})$
Jeśli w <b>modelu V</b> nie jest spełnione założenie, że $n_1, n_2$ są wystarczająco duże, to zamiast $\mathbf{prop.test}$ należy zastosować dokładny test Fishera <b>fisher.test</b> oparty na rozkładzie hipergeometrycznym.			